UNIVERSIDADE PRESBITERIANA MACKENZIE
Curso: Ciência de Dados

PROJETO APLICADO I
ETAPA 2

Análise de Dados de Comércio Eletrônico da Amazon

Projeto Aplicado I - BD - 2A 16

Antonio Jose de Oliveira Silva – 10755643 – ajos.padrao@gmail.com

Link do GitHub:

https://github.com/ThunderBoltCase/projeto-aplicado-amazon

Sumário

Sumário..... 2
1. Glossário..... 3
2. Objetivo de Estudo.....4
3. Apresentação da Empresa e Contexto..... 4
4. Problema de Pesquisa.....5
5. Estrutura dos Metadados.....6
6. Análise Exploratória de Dados (EDA).....7
6.1. Estatística Descritiva (Medidas de Posição e Dispersão).....9
6.2. Qualidade dos Dados e Anomalias..... 9

1. Glossário

- **EDA (Exploratory Data Analysis):** Abordagem estatística para resumir as principais características de um conjunto de dados, geralmente com métodos visuais.
- **Dataset:** Coleção de dados estruturados, geralmente organizada em tabelas.
- **Metadados:** Dados que fornecem informações sobre outros dados (ex: tipo, origem, validade).
- **Outlier:** Observação que apresenta uma grande discrepância em relação aos demais dados da mesma série.
- **Precificação Dinâmica:** Estratégia de ajuste de preços em tempo real baseada em algoritmos de demanda e oferta.

2. Objetivo de Estudo

O presente projeto tem como objetivo aplicar conceitos de ciência de dados em um contexto organizacional, utilizando dados reais ou simulados do comércio eletrônico, com foco específico na análise de produtos da Amazon. A proposta consiste em investigar informações relacionadas a produtos eletrônicos e acessórios, buscando identificar padrões de consumo, estratégias de precificação e o comportamento dos consumidores.

Como premissa, considera-se que os dados analisados representam um cenário típico de e-commerce, permitindo a aplicação de técnicas de análise exploratória de dados (EDA). Nesse contexto, o pensamento computacional é empregado na organização, estruturação e análise dos dados, possibilitando a decomposição do problema, a identificação de padrões relevantes e a proposição de soluções baseadas em evidências.

Dessa forma, o estudo pretende analisar como variáveis como preço, percentuais de desconto e volume de engajamento influenciam tanto a percepção de qualidade quanto a satisfação final do consumidor, contribuindo para uma compreensão mais aprofundada da dinâmica de vendas na plataforma.

3. Apresentação da Empresa e Contexto

- **Nome:** Amazon.com, Inc.
- **Missão:** Ser a empresa mais centrada no cliente do mundo.
- **Segmento:** Retalho eletrónico, computação em nuvem (AWS) e tecnologia.
- **Market Share:** Detém aproximadamente 38% do mercado de e-commerce nos EUA, sendo líder global no setor.
- **Recursos Humanos:** Aproximadamente 1,5 milhões de colaboradores globais.
- **Trabalhos em Destaque:** * **Sistemas de Recomendação:** Motores de filtragem colaborativa que personalizam a experiência de compra.
    - **Previsão de Procura:** Modelos de *machine learning* para otimização de *stock* e logística global.
    - **AWS (Amazon Web Services):** Infraestrutura de dados que suporta grande parte da internet moderna.

4. Problema de Pesquisa

- **O Problema:** Identificar se descontos agressivos em produtos eletrónicos impactam positivamente a satisfação do cliente ou se sinalizam produtos de menor qualidade.
- **O que incomoda:** A dificuldade em limpar dados brutos (símbolos monetários) para análise e a incerteza sobre a eficácia da margem de lucro sacrificada em promoções.
- **Decomposição:** Divisão entre limpeza de dados, análise de tendências centrais e visualização de correlação.
- **Padrões:** Identificação de que a maioria das avaliações concentra-se acima de 4.0, independentemente da faixa de preço.
- **Abstração:** Foco exclusivo nas métricas de Preço, Desconto e Nota, descartando imagens e descrições textuais.
- **Algoritmo:** Criação de um *pipeline* em Python que automatiza a conversão de tipos de dados e gera visualizações de tendência.

5. Estrutura dos Metadados

- Tipo de arquivo: CSV.
- Origem dos dados: Aberto (Dataset público extraído do Kaggle) https://www.kaggle.com/datasets/karkavelrajaj/amazon-sales-dataset

Os dados foram disponibilizados publicamente para fins educacionais e análise exploratória

- Sensibilidade: Baixa (Dados anonimizados, sem informações de identificação pessoal de acordo com a LGPD).
- Validade: Dados gerados entre 2020 e 2023. Tornam-se obsoletos com a atualização anual de catálogos e modelos eletrônicos.

Entre as limitações, destaca-se que os dados podem ter sido coletados ou simulados, sendo utilizados principalmente para fins acadêmicos

- Proprietário: Domínio público / Comunidade de Ciência de Dados.

Definição dos Atributos

Atributo	**Definição**	**Tipo de Dado**
`product_id`	Identificador único do produto	String
`product_name`	Nome completo do item	String
`category`	Hierarquia da categoria do produto	String
`discounted_price`	Preço de venda final com desconto	Float
`actual_price`	Preço de varejo original (tabela)	Float
`discount_percentage`	Percentual de desconto aplicado	Float
`rating`	Média das avaliações dos usuários (1 a 5)	Float
`rating_count`	Total de usuários que avaliaram o produto	Integer

6. Análise Exploratória de Dados (EDA)

Análise do Histograma (Distribuição de Notas): O gráfico revela que a satisfação do cliente na Amazon é predominantemente positiva, com uma forte concentração de produtos avaliados entre 4.0 e 4.5. Isso indica um catálogo composto majoritariamente por itens de alta qualidade percebida.

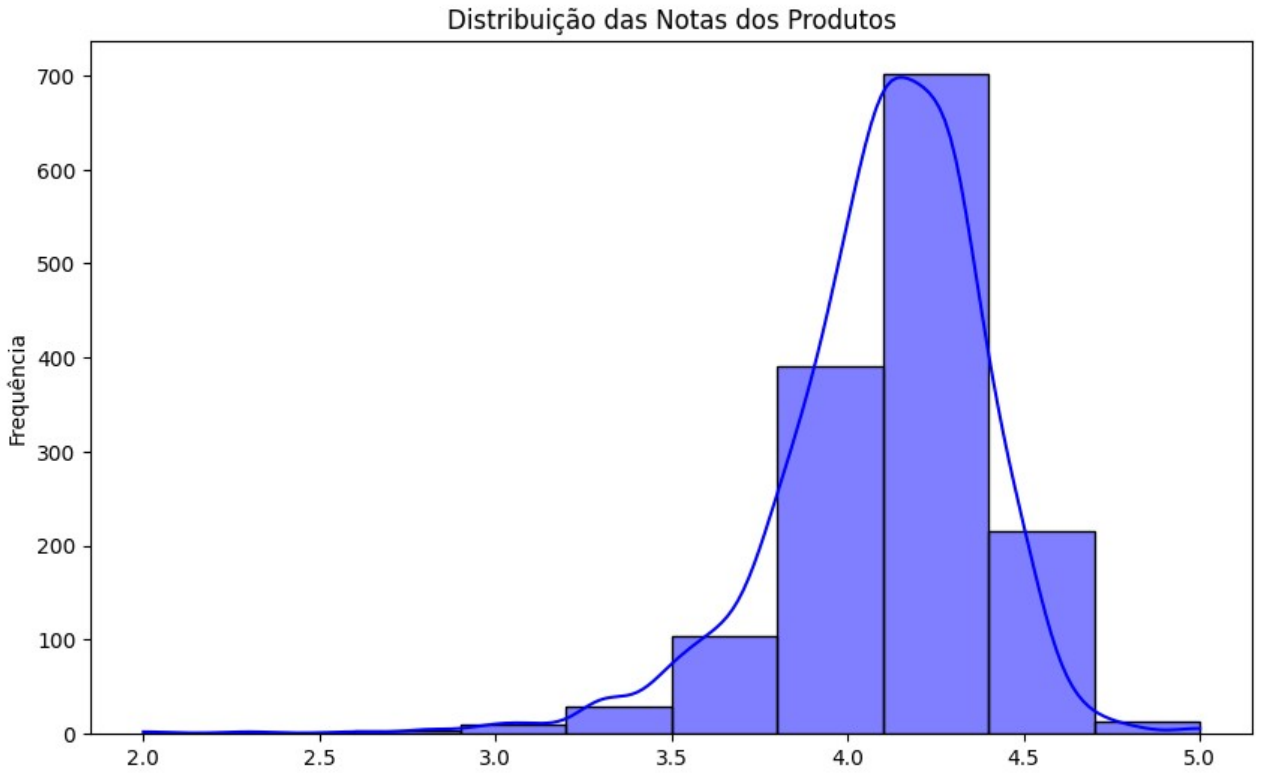

Análise do Gráfico de Dispersão (Desconto vs. Rating): A visualização demonstra que os pontos de avaliação estão dispersos de forma não linear em relação ao percentual de desconto. **Insight:** O desconto não dita a qualidade; produtos com 10% de desconto recebem notas tão altas quanto produtos com 80%, sugerindo que o consumidor separa a oportunidade de preço da percepção de valor do item.

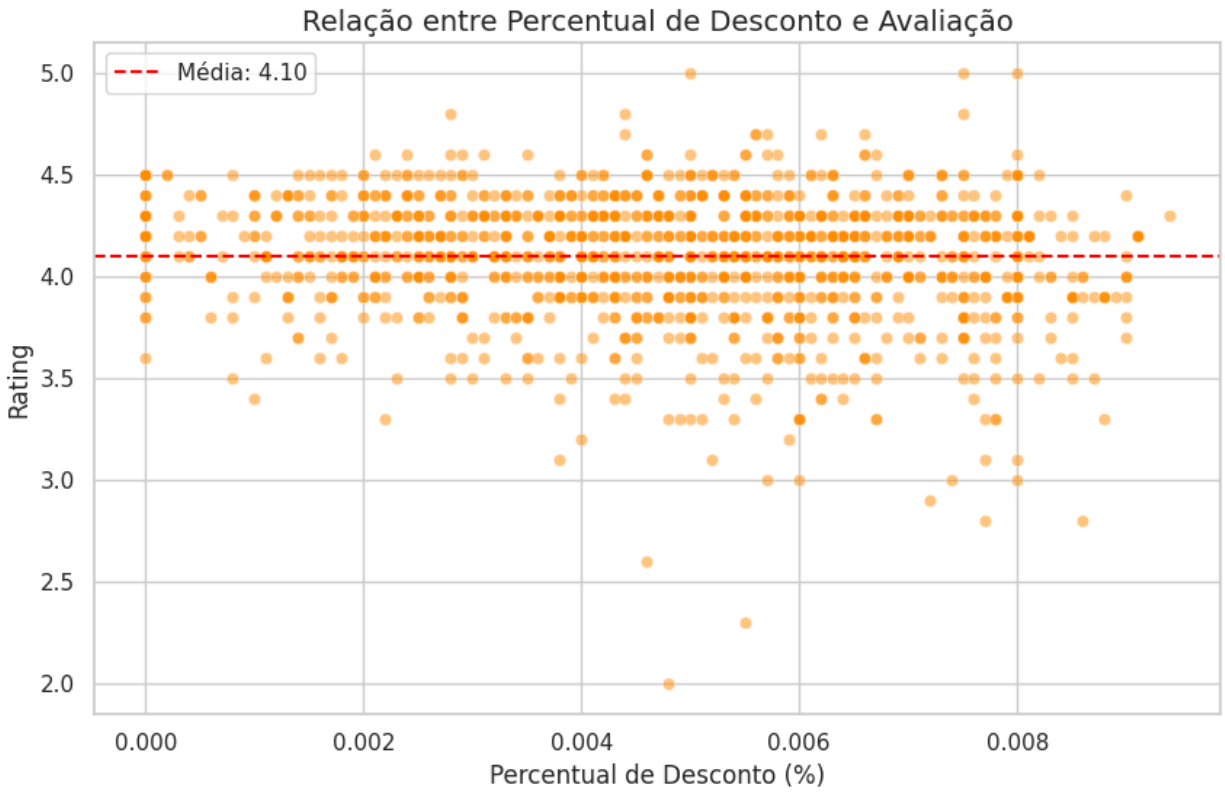

6.1. Estatística Descritiva (Medidas de Posição e Dispersão)

Métrica	Rating	Discount %	Actual Price
Média	4.09	47.6%	5,444.99
Mediana	4.10	50.0%	1,499.00
Moda	4.30	50.0%	999.00
Desvio Padrão	0.29	23.3%	10,874.70
Variância	0.08	0.05	1.18e+08
Coef. Variação	7.1%	48.9%	199.7%

6.2. Qualidade dos Dados e Anomalias

- **Valores Omissos:** Foram identificados 2 valores nulos na coluna `rating_count`, que devem ser tratados pela mediana para evitar distorções.
- **Anomalias:** A coluna `rating` continha um caractere especial "|" em um registo, impossibilitando a conversão direta para numérico; este foi tratado como ruído e removido.
- **Outliers:** Verificou-se uma alta dispersão no `actual_price` (CV de 199.7%), indicando a presença de produtos de luxo que se afastam drasticamente do ticket médio.